

FACULDADE ANTONIO MENEGHETTI - AMF
SISTEMAS DE INFORMAÇÃO

TRABALHO 1 - INTELIGÊNCIA ARTIFICIAL II 2026/02

Predição do Desempenho de Estudantes utilizando Machine Learning

Pedro Henrique Loureiro de Avila

2026

1. Dataset

Foi utilizado o Student Performance Dataset, disponibilizado pelo UCI Machine Learning Repository. O conjunto reúne informações de estudantes de escolas portuguesas e contém atributos acadêmicos, sociais, familiares e pessoais. Neste trabalho foi utilizado o arquivo student-mat.csv, referente à disciplina de Matemática, com 395 registros e 33 atributos originais.

Fonte oficial: UCI Machine Learning Repository - Student Performance. Link: <https://archive.ics.uci.edu/dataset/320/student+performance>

A escolha é adequada ao problema porque o conjunto contém a nota final G3 e variáveis que podem ser utilizadas para investigar e prever o desempenho acadêmico, como notas anteriores (G1 e G2), faltas, tempo de estudo e número de reprovações anteriores.

2. Problema e objetivo

O problema definido foi a classificação do desempenho final dos estudantes em duas classes: Aprovado e Reprovado. A variável alvo 'resultado' foi criada a partir da nota final G3: estudantes com G3 maior ou igual a 10 foram classificados como Aprovado, e estudantes com G3 menor que 10 como Reprovado.

O objetivo geral foi desenvolver e avaliar modelos de Machine Learning capazes de prever a aprovação ou reprovação de um estudante. A tarefa é de classificação supervisionada binária.

Também foi realizado um experimento comparando modelos sem as notas G1 e G2 com um modelo que utiliza essas notas. A intenção foi avaliar quanto o conhecimento do desempenho acadêmico anterior altera a capacidade preditiva.

3. Exploração e preparação dos dados

A análise inicial identificou 395 estudantes. Após a criação da variável 'resultado', o DataFrame passou a possuir 34 colunas. Não foram observados valores ausentes. Também foi realizada verificação de duplicidades antes da modelagem.

A variável alvo apresentou 265 estudantes aprovados (67,1%) e 130 reprovados (32,9%). Existe diferença entre o tamanho das classes, mas não um desequilíbrio extremo. Por esse motivo, a avaliação não foi baseada somente em acurácia, sendo consideradas também precision, recall, F1-score e matriz de confusão.




Figura 1 - Distribuição das classes Aprovado e Reprovado.




Figura 2 - Distribuição da nota final G3.




Figura 3 - Boxplots das notas G1, G2 e G3.

Na exploração das variáveis, reprovações anteriores (failures) apresentaram associação visual relevante com o resultado final: estudantes sem reprovações anteriores concentraram maior quantidade de aprovados, enquanto níveis maiores de failures apresentaram maior presença proporcional de reprovação. Essa relação é interpretada como associação nos dados e não como evidência de causalidade.




Figura 4 - Resultado por número de reprovações anteriores.




Figura 5 - Resultado por tempo de estudo.




Figura 6 - Distribuição de faltas por resultado final.

As variáveis categóricas foram transformadas por One-Hot Encoding, com tratamento de categorias não vistas por meio de `handle_unknown='ignore'`. As variáveis numéricas foram

padronizadas com StandardScaler. O pré-processamento foi integrado aos modelos com Pipeline, permitindo que os transformadores fossem ajustados a partir dos dados de treinamento e reduzindo o risco de vazamento de dados.

A nota G3 não foi utilizada como atributo de entrada, pois a variável 'resultado' foi criada diretamente a partir dela. Incluir G3 no treinamento caracterizaria data leakage, pois o modelo receberia a informação que determina a própria resposta.

4. Estratégia experimental

Inicialmente os dados foram divididos em 80% para treinamento e 20% para teste, utilizando `random_state=42` para reprodutibilidade e `stratify=y` para preservar aproximadamente a proporção das classes. O conjunto de teste ficou com 79 estudantes, sendo 53 aprovados e 26 reprovados.

Foram realizados dois cenários principais. No primeiro, G1, G2 e G3 foram removidos dos atributos de entrada, permitindo avaliar uma previsão baseada nas demais características. No segundo, G1 e G2 foram incluídos, mantendo G3 excluída. Para verificar a estabilidade do resultado final, também foi aplicada validação cruzada estratificada com 5 folds.

5. Modelagem

Foram utilizados dois algoritmos principais. A Regressão Logística foi adotada como modelo de referência (baseline) por ser um método simples e amplamente utilizado em classificação binária. Foi utilizado `max_iter=1000` para permitir a convergência do treinamento.

O segundo algoritmo foi Random Forest Classifier, com 200 árvores (`n_estimators=200`) e `random_state=42`. O Random Forest foi escolhido por conseguir modelar relações não lineares e interações entre diferentes características. Também foi realizado um experimento adicional com `class_weight='balanced'` para verificar se a ponderação das classes melhoraria a identificação de estudantes reprovados.

6. Avaliação

No cenário sem G1 e G2, a Regressão Logística obteve acurácia de 69,62%. Para a classe Reprovado, precision foi 57%, recall 31% e F1-score 40%. A matriz de confusão mostrou 47 aprovados e 8 reprovados corretamente classificados, enquanto 6 aprovados foram previstos como reprovados e 18 reprovados foram previstos como aprovados.




Figura 7 - Avaliação da Regressão Logística sem G1/G2.

O Random Forest sem G1/G2 apresentou acurácia de 70,89%. Para Reprovado, precision foi 62%, recall 31% e F1-score 41%. A melhoria de acurácia foi pequena e o principal problema permaneceu: apenas 8 dos 26 estudantes reprovados do teste foram identificados corretamente.




Figura 8 - Avaliação do Random Forest sem G1/G2.

O Random Forest com `class_weight='balanced'` não melhorou a identificação da classe minoritária nesta divisão. A acurácia caiu para 68,35%, o recall de Reprovado para 19% e o F1-score de Reprovado para 29%. O experimento foi mantido no relatório por demonstrar que uma técnica de balanceamento não garante melhoria automática.




Figura 9 - Random Forest balanceado sem G1/G2.

Com a inclusão de G1 e G2, o Random Forest apresentou melhora substancial: acurácia de 91,14%, precision de 88%, recall de 85% e F1-score de 86% para a classe Reprovado. Na matriz de confusão, 50 dos 53 aprovados e 22 dos 26 reprovados foram classificados corretamente.




Figura 10 - Random Forest com G1 e G2.

Modelo	Acurácia	Precision Reprovado	Recall Reprovado	F1 Reprovado
Regressão Logística sem G1/G2	69,62%	57%	31%	40%
Random Forest sem G1/G2	70,89%	62%	31%	41%
RF balanceado sem G1/G2	68,35%	56%	19%	29%
Random Forest com G1/G2	91,14%	88%	85%	86%

Tabela 1 - Comparação dos principais resultados no conjunto de teste.

Na validação cruzada estratificada com 5 folds, o Random Forest com G1/G2 obteve acurácia média de 90,9% ($\pm 3,3\%$), precision macro de 89,6% ($\pm 3,7\%$), recall macro de 90,1% ($\pm 4,3\%$) e F1 macro de 89,7% ($\pm 3,9\%$). O recall médio específico para Reprovado foi 87,7% ($\pm 7,8\%$), com valores por fold de 88,46%, 92,31%, 73,08%, 88,46% e 96,15%.

A curva ROC do modelo com G1/G2 apresentou ROC-AUC de 0,975 no conjunto de teste, indicando elevada capacidade de discriminação entre as duas classes nos dados avaliados.




Figura 11 - Curva ROC do Random Forest com G1/G2 (AUC = 0,975).

7. Análise dos resultados

Os experimentos mostram que as notas anteriores são determinantes para a capacidade preditiva deste modelo. Sem G1 e G2, os modelos ficaram próximos de 70% de acurácia e apresentaram recall de apenas 31% para Reprovado. Com G1 e G2, a acurácia subiu para 91,14% e o recall de Reprovado para 85% na divisão 80/20. A validação cruzada confirmou desempenho semelhante, com acurácia média de 90,9%.

A análise de importância do Random Forest sem G1/G2 apontou absences e failures como as características de maior importância relativa. Isso não implica causalidade: a importância indica que essas variáveis foram úteis para as divisões realizadas pelas árvores.




Figura 12 - Importância das características no Random Forest sem G1/G2.

No modelo com notas anteriores, G2 e G1 passaram a dominar a importância das características. G2 apresentou importância aproximada de 0,31 e G1 de 0,20, seguidas a grande distância por faltas e reprovações anteriores. Esse resultado é consistente com a melhora observada nas métricas quando o desempenho acadêmico anterior foi disponibilizado ao modelo.




Figura 13 - Importância das características no Random Forest com G1/G2.

Há um trade-off entre antecipação e desempenho. O cenário sem G1/G2 pode representar uma tentativa de identificação mais precoce, porém apresentou baixa capacidade de reconhecer reprovados. O cenário com G1/G2 produziu desempenho muito superior, mas depende de notas já obtidas durante o período letivo.


Entre as limitações estão o tamanho reduzido do conjunto (395 estudantes), a origem restrita a escolas portuguesas e a possibilidade de que o desempenho varie em outras populações. As importâncias do Random Forest não devem ser interpretadas como relações causais. Além disso, o modelo não deve ser utilizado isoladamente para decisões educacionais de alto impacto; os resultados representam um experimento acadêmico de classificação.

Não foram observados indícios suficientes, a partir dos resultados disponíveis, para afirmar overfitting ou underfitting de forma definitiva. Entretanto, a proximidade entre a acurácia do teste (91,14%) e a média da validação cruzada (90,9%) sugere que o resultado não dependeu exclusivamente de uma única divisão favorável. Uma análise futura poderia registrar explicitamente as métricas de treino e validação para aprofundar essa discussão.

8. Demonstração de funcionamento

Para a demonstração foi criada uma função que recebe os atributos de um estudante, aplica o mesmo Pipeline de pré-processamento utilizado no treinamento e retorna a classe prevista e as probabilidades de Aprovado e Reprovado.

Em um exemplo retirado do conjunto de teste, um estudante de 19 anos, tempo de estudo 1, uma reprovação anterior, zero faltas, G1=6 e G2=5 foi classificado como Reprovado, com 82,0% de probabilidade para Reprovado e 18,0% para Aprovado. O resultado real desse registro também era Reprovado.



```
[74] ✓ Os  print("DADOS PRINCIPAIS DO ESTUDANTE")
print("-" * 35)

print("Idade:", aluno_teste["age"])
print("Tempo de estudo:", aluno_teste["studytime"])
print("Reprovações anteriores:", aluno_teste["failures"])
print("Faltas:", aluno_teste["absences"])
print("G1:", aluno_teste["G1"])
print("G2:", aluno_teste["G2"])

print()

prever_estudante(aluno_teste)

print(
    "\nResultado real:",
    y_test_notas.iloc[0]
)
```

▼ ... DADOS PRINCIPAIS DO ESTUDANTE

Idade: 19
Tempo de estudo: 1
Reprovações anteriores: 1
Faltas: 0
G1: 6
G2: 5

=====

PREVISÃO DE DESEMPENHO DO ESTUDANTE

=====

Resultado previsto: Reprovado

Probabilidades:
Aprovado: 18.00%
Reprovado: 82.00%

Resultado real: Reprovado

Figura 14 - Demonstração com estudante do conjunto de teste.

Também foram criados dois cenários fictícios. No primeiro, com idade 17, studytime=3, failures=0, absences=2, G1=14 e G2=15, o modelo retornou Aprovado com 95,5% de

probabilidade. No segundo, com studytime=1, failures=2, absences=18, G1=7 e G2=6, retornou Reprovado com 77,5% de probabilidade. Esses cenários demonstram o funcionamento do classificador e não devem ser interpretados como evidência de causalidade entre alterações individuais e o resultado.

```
aluno_novo = X_test_notas.iloc[0].copy()

aluno_novo["age"] = 17
aluno_novo["studytime"] = 3
aluno_novo["failures"] = 0
aluno_novo["absences"] = 2

aluno_novo["G1"] = 14
aluno_novo["G2"] = 15

prever_estudante(
    aluno_novo.to_dict()
)
aluno_novo_2 = X_test_notas.iloc[0].copy()

aluno_novo_2["age"] = 17
aluno_novo_2["studytime"] = 1
aluno_novo_2["failures"] = 2
aluno_novo_2["absences"] = 18

aluno_novo_2["G1"] = 7
aluno_novo_2["G2"] = 6

prever_estudante(
    aluno_novo_2.to_dict()
)

...
=====
PREVISÃO DE DESEMPENHO DO ESTUDANTE
=====

Resultado previsto: Aprovado

Probabilidades:
Aprovado: 95.50%
Reprovado: 4.50%
=====
PREVISÃO DE DESEMPENHO DO ESTUDANTE
=====

Resultado previsto: Reprovado

Probabilidades:
Aprovado: 22.50%
Reprovado: 77.50%
```

Figura 15 - Demonstração com dois cenários fictícios.

9. Extensão opcional

Não foi implementada interface gráfica, workflow automatizado ou agente de IA. A solução foi desenvolvida em Python no Google Colab, utilizando um Pipeline de pré-processamento e classificação. Essa opção manteve o foco nos objetivos obrigatórios do trabalho: exploração, preparação, treinamento, avaliação e interpretação do modelo.

10. Reprodutibilidade

Para reproduzir o experimento, deve-se obter o arquivo `student-mat.csv` do Student Performance Dataset, executar o notebook do projeto em ordem, criar a variável `resultado` a partir de `G3`, realizar o pré-processamento com `OneHotEncoder` e `StandardScaler`, dividir os dados com `test_size=0.20`, `random_state=42` e `stratify`, e treinar os modelos descritos. Recomenda-se registrar no repositório as dependências utilizadas (`pandas`, `numpy`, `matplotlib`, `seaborn`, `scikit-learn` e `joblib`) e manter o notebook executável.

11. Conclusão

O trabalho demonstrou a aplicação completa de um fluxo de Machine Learning para classificação de desempenho estudantil. Os modelos sem `G1` e `G2` apresentaram dificuldade para identificar estudantes reprovados. A inclusão das notas anteriores elevou substancialmente o desempenho do Random Forest, que alcançou 91,14% de acurácia no teste, recall de 85% para Reprovado e ROC-AUC de 0,975. A validação cruzada apresentou acurácia média de 90,9% e recall médio de 87,7% para Reprovado, reforçando a estabilidade do resultado dentro do conjunto analisado.

Os resultados mostram que `G1` e `G2` possuem grande valor preditivo neste dataset, mas o modelo possui limitações de tamanho e representatividade da amostra. Assim, os resultados devem ser interpretados no contexto do conjunto de dados utilizado e não como regras gerais sobre desempenho escolar.

Referências

CORTEZ, Paulo; SILVA, Alice Maria Gonçalves. Using Data Mining to Predict Secondary School Student Performance. In: Proceedings of 5th Annual Future Business Technology Conference (FUBUTEC 2008). Porto, 2008.

UCI MACHINE LEARNING REPOSITORY. Student Performance. Disponível em: <https://archive.ics.uci.edu/dataset/320/student+performance>. Acesso em: 14 set. 2026.

SCIKIT-LEARN DEVELOPERS. scikit-learn: Machine Learning in Python. Documentação das classes `LogisticRegression`, `RandomForestClassifier`, `Pipeline`, `ColumnTransformer` e métricas de classificação.